

# Optymalizacja

## Laboratorium 11

Jakub Ciszewski, Wiktor Smaga

20 czerwca 2024

### 1 Zadanie 1

1. Obliczamy gradienty funkcji  $f$  względem  $x$  i  $y$ .
2. Rozwiązujemy układ równań, gdzie gradienty są równe zero, aby znaleźć punkty krytyczne.
3. Dla każdego znalezionej punktu krytycznego wykonujemy operacje:
  - (a) Oblicz macierz Hessego funkcji.
  - (b) Podstawiamy wartości  $x$ ,  $y$  do macierzy Hessego
  - (c) Oblicz wartości własne macierzy Hessego (Rozwiązujemy równanie charakterystyczne)
  - (d) Klasyfikuj punkt krytyczny na podstawie wartości własnych:
    - Minimum, jeśli wszystkie wartości własne są dodatnie.
    - Maksimum, jeśli wszystkie wartości własne są ujemne.
    - Punkt siodłowy, jeśli wartości własne mają różne znaki.

```

Function f1(x, y):
  Critical point: {x: 0, y: 0}, Classification: saddle point

Function f2(x, y):
  Critical point: {x: -1, y: -1}, Classification: minimum
  Critical point: {x: 0, y: 0}, Classification: saddle point
  Critical point: {x: 1, y: 1}, Classification: minimum
  Critical point: {x: -I, y: I}, Classification: complex coordinates
  Critical point: {x: I, y: -I}, Classification: complex coordinates
  Critical point: {x: sqrt(2)*(-1 - I)/2, y: sqrt(2)/2 - sqrt(2)*I/2}, Classification: complex coordinates
  Critical point: {x: sqrt(2)*(-1 + I)/2, y: sqrt(2)/2 + sqrt(2)*I/2}, Classification: complex coordinates
  Critical point: {x: sqrt(2)*(1 - I)/2, y: -sqrt(2)/2 - sqrt(2)*I/2}, Classification: complex coordinates
  Critical point: {x: sqrt(2)*(1 + I)/2, y: -sqrt(2)/2 + sqrt(2)*I/2}, Classification: complex coordinates

Function f3(x, y):
  Critical point: {x: -1, y: -1}, Classification: maximum
  Critical point: {x: 0, y: -1}, Classification: saddle point
  Critical point: {x: 0, y: 0}, Classification: saddle point
  Critical point: {x: 1, y: 0}, Classification: minimum

Function f4(x, y):
  Critical point: {x: 1, y: 1}, Classification: saddle point

```

Wykres 1: Wynik powyższej operacji

## 1.1 Minima i maksima globalne

**Funkcja**  $f_1(x, y) = x^2 - 4xy + y^2$

Przy  $x$  lub  $y$  dążącym do nieskończoności, wyrażenie  $x^2$  oraz  $y^2$  dominuje, co sprawia, że funkcja dąży do nieskończoności. Nie posiada więc minimum globalnego ani maksimum globalnego.

**Funkcja**  $f_2(x, y) = x^4 - 4xy + y^4$

Przy  $x$  lub  $y$  dążącym do nieskończoności, wyrażenie  $x^4$  oraz  $y^4$  dominuje, co sprawia, że funkcja dąży do nieskończoności. Nie posiada więc minimum globalnego ani maksimum globalnego.

**Funkcja**  $f_3(x, y) = 2x^3 - 3x^2 - 6xy(x - y - 1)$

Przy  $x$  lub  $y$  dążącym do nieskończoności, wyrażenie  $2x^3$  dominuje, co sprawia, że funkcja dąży do  $\pm$  nieskończoności w zależności od znaku  $x$ . Nie posiada więc minimum globalnego ani maksimum globalnego.

**Funkcja**  $f_4(x, y) = (x - y)^4 + x^2 - y^2 - 2x + 2y + 1$

Przy  $x$  lub  $y$  dążącym do nieskończoności, wyrażenie  $(x - y)^4$  dominuje, co sprawia, że funkcja dąży do nieskończoności. Nie posiada więc minimum globalnego ani maksimum globalnego.

## 2 Zadanie 2 - wyprowadzenie wzoru na gradient

Funkcja F jest zdefiniowana jako:

$$F(x^{(0)}, x^{(1)}, \dots, x^{(n)}) = \lambda_1 \sum_{i=0}^n \sum_{j=1}^k \frac{1}{\epsilon + \|x^{(i)} - r^{(j)}\|_2^2} + \lambda_2 \sum_{i=0}^{n-1} \|x^{(i+1)} - x^{(i)}\|_2^2$$

1. Składnik pierwszy:

$$\frac{\partial}{\partial x^{(i)}} \left( \sum_{j=1}^k \frac{1}{\epsilon + \|x^{(i)} - r^{(j)}\|_2^2} \right) = \sum_{j=1}^k \frac{\partial}{\partial x^{(i)}} \left( \frac{1}{\epsilon + \|x^{(i)} - r^{(j)}\|_2^2} \right)$$

Stosując regułę łańcuchową:

$$= \sum_{j=1}^k - \frac{1}{(\epsilon + \|x^{(i)} - r^{(j)}\|_2^2)^2} \cdot \frac{\partial}{\partial x^{(i)}} (\epsilon + \|x^{(i)} - r^{(j)}\|_2^2)$$

Korzystając z tego, że:  $\frac{\partial \|x\|^2}{\partial x} = 2x$ :

$$= \sum_{j=1}^k - \frac{2(x^{(i)} - r^{(j)})}{(\epsilon + \|x^{(i)} - r^{(j)}\|_2^2)^2}$$

2. Składnik drugi:

$$\frac{\partial}{\partial x^{(i)}} \left( \|x^{(i+1)} - x^{(i)}\|_2^2 + \|x^{(i)} - x^{(i-1)}\|_2^2 \right)$$

Stosując fakt, że  $\|x^{(i+1)} - x^{(i)}\|_2^2 = (x^{(i+1)} - x^{(i)})^T (x^{(i+1)} - x^{(i)})$ :

$$= 2(x^{(i)} - x^{(i+1)}) + 2(x^{(i)} - x^{(i-1)})$$

3. Łącząc gradienty:

$$\nabla F(x^{(i)}) = \lambda_1 \sum_{j=1}^k - \frac{2(x^{(i)} - r^{(j)})}{(\epsilon + \|x^{(i)} - r^{(j)}\|_2^2)^2} + \lambda_2 \left( 2(x^{(i)} - x^{(i+1)}) + 2(x^{(i)} - x^{(i-1)}) \right)$$

**Finalny Gradient**

$$\nabla F = \left[ \frac{\partial F}{\partial x^{(0)}}, \frac{\partial F}{\partial x^{(1)}}, \dots, \frac{\partial F}{\partial x^{(n)}} \right]$$

Gdzie:

$$\frac{\partial F}{\partial x^{(i)}} = \lambda_1 \sum_{j=1}^k - \frac{2(x^{(i)} - r^{(j)})}{(\epsilon + \|x^{(i)} - r^{(j)}\|_2^2)^2} + \lambda_2 \left( 2(x^{(i)} - x^{(i+1)}) + 2(x^{(i)} - x^{(i-1)}) \right)$$

### 3 Zadanie 3 - Algorytm największego spadku z przeszukiwaniem liniowym

#### Krok 1: Inicjalizacja

Algorytm generuje początkową ścieżkę złożoną z losowo wygenerowanych punktów  $x^{(i)}$  na mapie

#### Krok 2: Obliczanie gradientu

Przy każdej iteracji algorytmu optymalizacji obliczany jest gradient funkcji celu dla każdego punktu. Znając gradient funkcji celu wiemy w którą stronę przesunąć naszą funkcję aby osiągnęła mniejszą wartość.

$$\nabla F(x) = \left[ \frac{\partial F}{\partial x^{(0)}}, \frac{\partial F}{\partial x^{(1)}}, \dots, \frac{\partial F}{\partial x^{(n)}} \right]$$

Gdzie:

$$\frac{\partial F}{\partial x^{(i)}} = \lambda_1 \sum_{j=1}^k -\frac{2(x^{(i)} - r^{(j)})}{(\epsilon + \|x^{(i)} - r^{(j)}\|_2^2)^2} + \lambda_2 \left( 2(x^{(i)} - x^{(i+1)}) + 2(x^{(i)} - x^{(i-1)}) \right)$$

#### Krok 3: Przeszukiwanie liniowe z użyciem złotego podziału

Definiujemy funkcję  $\phi(\alpha) = F(x - \alpha \nabla F(x))$ .

Minimalizacja jej wyniku pozwoli nam na określenie, jak daleko należy przesunąć nasz punkt (obliczyć skalar  $\alpha$ ). Używamy metody złotego podziału w celu znalezienia minimum funkcji  $\phi$ .

#### Metoda złotego podziału

Wybierz początkowy przedział  $[a, b]$  dla  $\alpha$ . Iteracyjnie zawężaj przedział według metody złotego podziału:

$$\begin{aligned}\phi &= \frac{1 + \sqrt{5}}{2} \\ c &= b - \frac{b - a}{\phi} \\ d &= a + \frac{b - a}{\phi}\end{aligned}$$

Oblicz wartości funkcji:

$$f(c), \quad f(d)$$

Aktualizuj przedział:

- Jeśli  $f(c) < f(d)$ , nowy przedział to  $[a, d]$ .
- Jeśli  $f(c) \geq f(d)$ , nowy przedział to  $[c, b]$ .

Powtarzaj, aż przedział będzie wystarczająco mały.

#### **Krok 4: Aktualizacja punktu**

$$x_{new} = x - \alpha \nabla F(x)$$

gdzie  $\alpha$  to optymalny krok wyznaczony w poprzednim kroku.

## Zadanie 4 - znalezienie optymalnej ścieżki dla robota

Uruchamiamy nasz algorytm dla poniższych wartości

$n = 20$  - liczba punktów ścieżki

$k = 30$  - liczba przeszkód

$x_0 = (0,0)$  - punkt startowy

$x_n = (20, 20)$  - punkt końcowy

$r = \text{np.random.uniform}(0, 20, (k, 2))$  - wygenerowane pozycje przeszkód


$\lambda_1 = 1$  - waga pierwszej części funkcji celu


$\lambda_2 = 1$  - waga drugiej części funkcji celu

$\epsilon = 1 \times 10^{-13}$  - wartość zapobiegająca dzieleniu przez zero

Liczba iteracji = 400


### Wywołanie 1

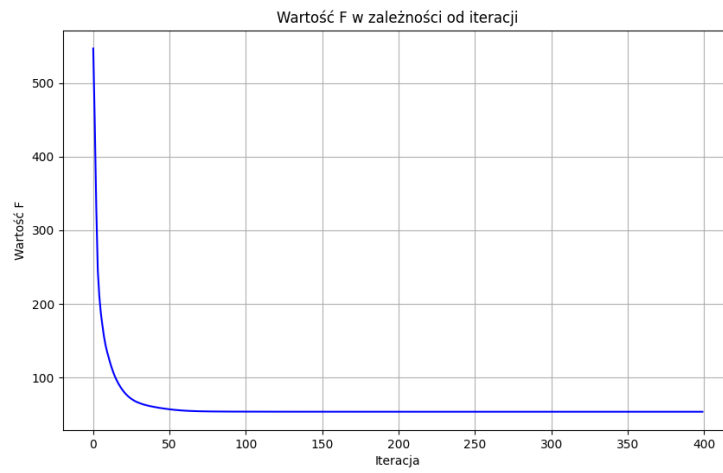




Iteracja	Wartość funkcji $F$
0	543.38
10	111.66
50	73.69
100	72.76
400	72.24


## Wywołanie 2



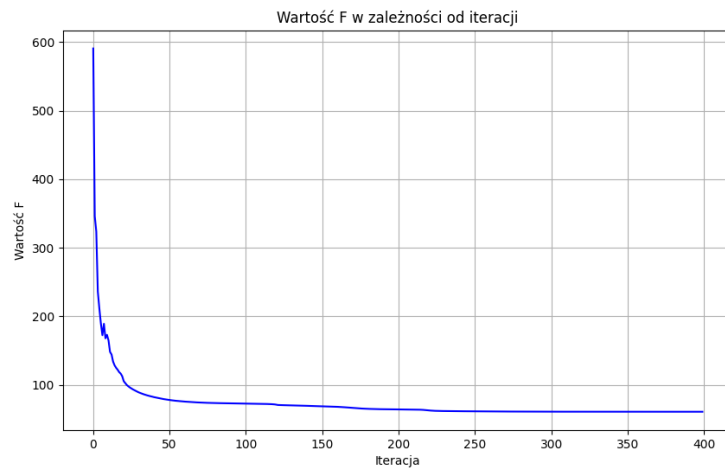


Iteracja	Wartość funkcji $F$
0	546.87
10	127.94
50	56.73
100	53.53
400	53.39

### Wywołanie 3




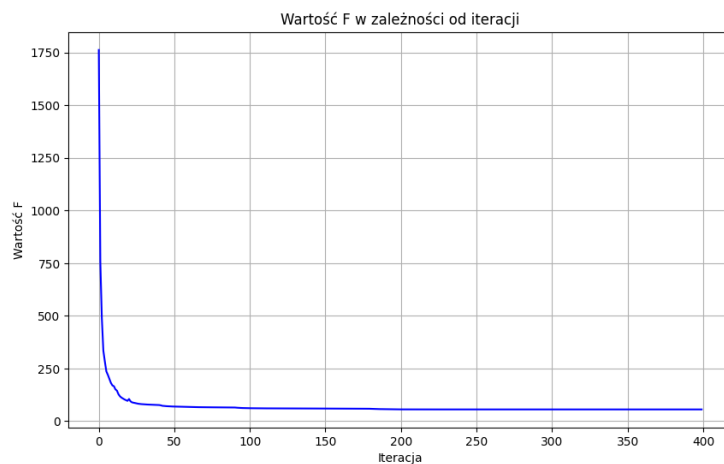




Iteracja	Wartość funkcji $F$
0	590.6506235516267
10	165.01400211803772
50	78.04074862722149
100	72.8280300065097
400	60.9391683488607

## Wywołanie 4







Iteracja	Wartość funkcji $F$
0	1762.54
10	166.02
50	69.54
100	61.73
400	55.87

## Wywołanie 5

W wywołaniu piątym naszymi punktami startowymi  $x_i$  są punkty ustawione w linii prostej






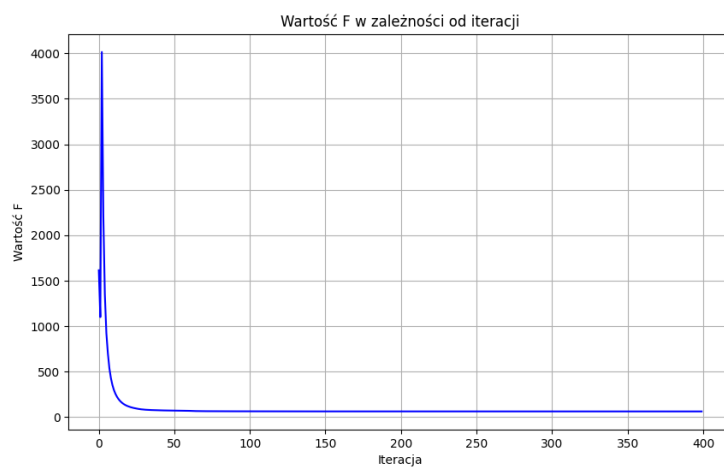
Iteracja	Wartość funkcji $F$
0	66.58
10	63.46
50	62.58
100	61.74
400	60.45

## 4 Testowanie dla stałej wartości skłara

Testowanie dla skłara  $\alpha = 0.05$


Zamiast złotego podziału użyliśmy wartości stałej skłara

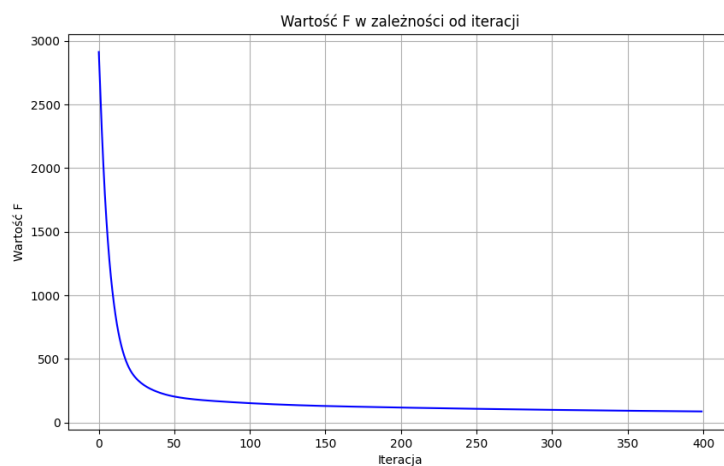




Iteracja	Wartość funkcji $F$
0	1615.00
10	298.50
50	72.21
100	64.26
400	63.14


Testowanie dla skłara  $\alpha = 0.01$






Iteracja	Wartość funkcji $F$
0	2911.95
10	935.21
50	204.73
100	152.77
400	87.89

## 5 Podsumowanie



Wykres 2: Porównanie wartości funkcji  $F$  pierwszych 5 wywołań dla skalara obliczanego przy pomocy złotego podziału



Wykres 3: Porównanie wartości funkcji  $F$  wywołań z losowymi punktami startowymi, linią prostą jako punkty startowe oraz skalara  $\alpha = 0.05$  i  $0.01$

Jak widać skalara równy  $0.01$  radzi sobie dla iteracji od 10 do 50 gorzej od inny obranych sposobów

## 6 Wnioski

- Gradient funkcji celu pozwala nam na określenie kierunku, w którym funkcja rośnie najbardziej, przez co wiemy, w którym kierunku powinniśmy zmienić położenie punktu, aby zmniejszyć wartość funkcji celu.
- Przeszukiwanie liniowe jest techniką używaną do znalezienia optymalnej wartości skalarnej (kroku  $\alpha$ ) wzdłuż danego kierunku. Dzięki przeszukiwaniu liniowemu możemy precyzyjnie dostosować krok, aby zmniejszyć funkcję celu wzdłuż kierunku przeciwnym do gradientu.
- Metoda złotego podziału (golden section search) jest efektywną metodą przeszukiwania liniowego, która minimalizuje liczbę ewaluacji funkcji celu potrzebnych do znalezienia optymalnej wartości  $\alpha$ . Wykorzystuje ona proporcje złotego podziału do zawężania przedziału, w którym znajduje się minimum, co przyspiesza proces optymalizacji.
- Wyznaczanie skalaru przy pomocy metody złotego podziału pozwala nam na szybszą optymalizację dla małej ilości iteracji w porównaniu do stałego skalaru
- Punkty startowe ułożone w linię początkowo dają lepszy rezultat. Różnica następnie zmniejsza się przy większej ilości iteracji